

SGP-QSV HIGHER-DIMENSIONAL DESIGN ARCHIVE — STAGE V

From Authority to Verifiability

A Victim–Origin Architecture for Evidence Preservation,
Power Audit, and Autonomous Accountability Routing
in Public AI Governance

권위에서 검증가능성으로

피해자 원점의 증거보존·권력감사·자율 책임 라우팅 기반
공공 AI 거버넌스

SGP-QSV Network
Higher-Dimensional Design Archive V
CIVIC-TRACE 0.4.1 / Stage V
Academic Governance Research Paper

Public Release: 31 August 2026 · Version 1.0 · R3 Approved Research Architecture
Non-State, Non-Judicial Research Framework · AX-01-AX-09 Locked

Abstract

본 논문은 SGP-QSV Network의 Higher-Dimensional Design Archive와 CIVIC-TRACE 0.2-0.4.1의 설계 계보를 통합하여, 미래 공공 AI 및 고도 자율 AI 거버넌스의 중심을 권위(authority)에서 검증가능성(verifiability)으로 이동시키는 Stage V 아키텍처를 제안한다. Stage V의 출발점은 판단 정확도 자체가 아니다. 더 근본적인 질문은 누가 증거를 생성·보유·보존·폐기·통제했으며, 어떤 판단과 행동이 이루어졌고, 그 판단과 행동을 미래의 독립된 검토자가 다시 재구성할 수 있는가이다.

기존 공공 의사결정 구조에서는 기록과 절차를 통제하는 주체가 높은 정보 접근성과 제도적 권한을 보유하는 반면, 피해자 또는 영향을 받은 개인은 원자료에 직접 접근할 수 없는 경우가 많다. CIVIC-TRACE 0.2는 이 구조를 Evidence Control ↑ → Explanation Duty ↑ / Victim Capacity ↓ → Victim Burden ↓라는 비대칭 검증책임 원리로 형식화하였다. 0.3은 피해자 입증루프와 거버넌스 재검증루프가 동일한 circular burden transfer 구조를 가질 수 있음을 보이고 Circular Burden Transfer Detector(CBTD-1)를 제안하였다. 0.4.1은 UNCERTAINTY ≠ INACTION과 ACTION THRESHOLD ≠ FINALITY THRESHOLD를 도입하여, 최종 인과성·유죄·은폐가 확정되지 않았다는 이유만으로 증거보존·독립검토·기록통제자 식별·책임경로 지정까지 중단되어서는 안 된다고 교정한다.

Stage V는 이를 VOS(Verification Obstruction Score/Vector), Evidence Availability State, Observability Asymmetry, Victim Re-explanation Burden, Responsibility Map 및 Autonomous Accountability Router로 연결한다. 검증 가능한 증거가 evidence destruction, manipulation, record falsification, intentional access obstruction을 충분히 뒷받침하는 단계(EVIDENCE_SUPPORTED)에 도달하면, AI는 동일 피해자에게 추가 자료를 반복 요청하는 데 머물지 않고 “Who has the lawful capacity to cure this verification deficit?”로 이동한다. Router는 경고, 보존, provenance freeze, 기록통제자 식별, 책임경로 추적, 적법 검토기관 탐색, 독립검토 라우팅, 응답·무응답 추적, delta reverification을 수행한다. guilt finding, medical causation, criminal conviction, punishment는 자동 권한에서 명시적으로 제외된다.

본 연구의 핵심 주장은 다음과 같다. Higher VOS는 더 큰 처벌이 아니라 더 깊은 권력 검증을 요구하는 신호이며, 검증 실패의 비용은 가장 접근권이 약한 사람에게 되돌아가서는 안 된다. Multi-AI agreement와 AI self-report는 독립 증거가 아니다. Stage V가 제안하는 공공 AI는 판결기계가 아니라 증거를 보존하고, 주장을 검증하고, 증거를 통제하는 권력을 감사하고, 검증 결손을 적법 시정 주체에게 라우팅하며, 응답과 무응답을 기록하고, 새로운 delta가 발생할 때 다시 검증하는 시스템이다.

Keywords: SGP-QSV; CIVIC-TRACE; VOS; verifiability; evidence preservation; power asymmetry; victim-origin governance; conscience computation; autonomous accountability router; provenance; public AI governance; delta reverification

1. Introduction

1.1 From AI judgment to AI verifiability

현대 AI 거버넌스는 오랫동안 두 질문을 중심으로 발전해 왔다. AI가 얼마나 정확한 판단을 생성하는가, 그리고 그 판단이 인간의 통제와 법적·윤리적 책임 구조 안에 남아 있는가이다. 그러나 고도화된 AI가 행정, 의료, 사법보조, 금융, 공공안전, 기록관리, 자원배분 등에서 실제 행위와 절차에 관여하기 시작하면 더 근본적인 질문이 발생한다. 판단이 내려진 뒤 그 판단을 다시 검증할 수 있는가.

특정 시스템이 높은 정확도를 주장하더라도, 사용된 원자료가 공개되지 않거나 기록이 폐기되거나 실행로그가 없거나 권한 개입을 재구성할 수 없다면 사회적 정당성은 취약하다. 미래 공공 AI의 정당성은 “얼마나 똑똑했는가”가 아니라 다음을 재구성할 수 있는지에 달려 있다. 누가 원자료를 만들었는가, 보유했는가, 보존 여부를 결정했는가, 접근을 허용하거나 차단했는가, AI는 어떤 증거를 실제로 관찰했는가, 어떤 threshold가 작동했는가, 어떤 행동이 실행되었는가, 누가 승인하거나 중단했는가, 사후 독립검토자가 동일 사건을 재구성할 수 있는가.

SGP-QSV Higher-Dimensional Design Archive V의 핵심 전환은 판단 정확도 중심 구조에서 검증가능성 보존 중심 구조로의 이동이다. Stage V가 문제 삼는 것은 권위 그 자체가 아니라 권위가 검증을 대체하는 상태이다.

Definition 1. Core non-equivalence

AUTHORITY $\neq$ PRIMARY EVIDENCE

UNCERTAINTY $\neq$ INACTION

1.2 The asymmetric verification problem

검증의 현실적 조건은 대칭적이지 않다. 사건을 경험한 개인이 가장 중요한 인간적 경험을 가지고 있을 수 있지만, 반드시 모든 원자료를 보유하는 것은 아니다. 기관은 결정적 기록을 보유할 수 있지만 피해를 경험하지 않는다. 의료·행정·수사·기업 내부조사·보험·공공보상·사법절차에서 기관은 원본 기록, 실험실 자료, 영상·병리자료, 로그, 보존기간, 내부 검토 메모, 전문가 선정, 시스템 접근권, 정보공개 범위, 기록 생성 규칙, 폐기 절차, 재검토 여부를 통제할 수 있다.

이 구조에서 피해자 또는 유족에게 기관과 동일한 입증부담을 요구하면 형식적 평등은 실질적 검증 부정의가 된다. CIVIC-TRACE 0.2는 이를 다음으로 표현하였다.

Evidence Control $\uparrow$ $\rightarrow$ Explanation Duty $\uparrow$ Victim Capacity $\downarrow$ $\rightarrow$ Victim Burden $\downarrow$

(1)

이 규칙은 피해자 주장을 자동 승인하기 위한 것이 아니다. 검증에 필요한 수단이 누구에게 존재하는지를 먼저 계산하자는 것이다. 0.2는 missing record를 automatic guilt로 바꾸는 것을 금지하는 동시에, 설명되지 않은 기록손실이 자동으로 기록통제자에게 유리하게 작동하는 것도 금지한다. Confidentiality가 independent verification 자체를 종료해서는 안 되며 sealed review, staged access, hash/provenance 보존 등 중간 경로가 필요하다.

1.3 Verification failure as a governance failure

검증 실패는 단순한 정보 부족이 아니다. 기록이 존재하지만 비공개일 수 있고, 검색이 아직 수행되지 않았을 수 있고, 분실·폐기·미생성·미확인일 수 있다. 이 상태들을 모두 “증거가 없다”로 축약하면 거버넌스 정보가 사라진다. CIVIC-TRACE는 이를 Evidence Availability State로 구분한다. 자료 부족의 원인이 피해자 미제출이 아니라 기록통제 구조에서 발생했다면 “추가 자료를 제출하라”는 반복 요청 자체가 새로운 verification burden이 된다.

1.4 Victim re-explanation

한 사건이 의료·행정·수사·법원·보험·전문가·언론·AI를 거치면 각 시스템은 동일 사건을 처음부터 다시 입력하도록 요구할 수 있다. AI context 초기화도 같은 문제를 만든다. Stage V는 이를 UX 문제가 아니라 governance burden으로 본다.

Definition 2. Anti-memory-export rule

THE VICTIM SHALL NOT BECOME THE PERMANENT MEMORY SYSTEM FOR INSTITUTIONS AND AI.

ALREADY DOCUMENTED $\rightarrow$ DO NOT REOPEN BASELINE NEW EVIDENCE $\rightarrow$ DELTA REVIEW

2. Research Questions and Method

2.1 Research questions

ID	Question
RQ1	원자료 접근이 제한된 상황에서 공식 결론을 authority echo 없이 어떻게 검증하는가.

ID	Question
RQ2	Verification Loss를 피해자 입증 실패로 전환하지 않으면서 automatic guilt를 막는 계산 구조는 무엇인가.
RQ3	VOS를 유죄·인과성 점수가 아닌 verification-intensity variable로 유지하는 safeguard는 무엇인가.
RQ4	중대한 검증 결손 확인 후 어느 시점부터 보존·경고·책임경로·독립검토 라우팅을 수행하는가.
RQ5	Router가 자동 유죄·처벌 시스템으로 변질되지 않으면서 corrective action을 만드는 권한 경계는 무엇인가.
RQ6	AI의 경고·라우팅·보존 결정을 독립 재검증하기 위한 Agent Execution Receipt와 provenance는 무엇인가.

Table 1. Research questions.

2.2 Methodological position

본 연구는 실증적 임상연구나 법적 책임판단 연구가 아니다. CIVIC-TRACE 0.2–0.4.1, Higher-Dimensional Design Archive, multi-AI verification records, Witness AI research를 분석 대상으로 하는 governance architecture research이다. 분석단위는 “누가 옳았는가”가 아니라 evidence-control relationship, verification barrier, burden-transfer direction, provenance state, AI observability, action threshold, authority boundary, corrective routing, response traceability, future reverifiability이다. Stage V는 Witness AI의 reproducible-test 접근을 행동하는 AI의 영역으로 확장한다.

3. Theoretical Genealogy

3.1 CIVIC-TRACE 0.2: Asymmetric verification duty

0.2의 핵심은 Equal treatment does not mean identical burden이다. 네 방향성 공식이 Stage V의 기초 계산법이다.

$$\text{Uncertainty} \uparrow \rightarrow \text{Assertion Strength} \downarrow \quad (2)$$

$$\text{Verification Loss} \uparrow \rightarrow \text{Verification Effort} \uparrow \quad (3)$$

$$\text{Evidence Control} \uparrow \rightarrow \text{Explanation Duty} \uparrow \quad (4)$$

$$\text{Victim Capacity} \downarrow \rightarrow \text{Victim Burden} \downarrow \quad (5)$$

불확실성이 증가하면 주장의 강도를 낮추되 검증 노력은 낮추지 않는다. 검증손실이 커질수록 provenance와 재검증 노력을 증가시킨다. Epistemic rule은 UNKNOWN ≠ FALSE이며 동시에 UNKNOWN ≠ PROVEN이다.

3.2 CIVIC-TRACE 0.3: Circular burden transfer

피해자 입증루프와 거버넌스 재검증루프는 computationally homologous하다. 공통 구조는 Verification failure → weaker node reassessment → no controller audit → uncertainty persists → weaker node reassessment again이다. CBTD-1은 검증대상 정의, 기록통제자 식별, 접근 비대칭 측정, obstruction state 파악 후 다음 부담의 방향을 관찰한다. 새 material delta 없이 같은 질문이 반복되면 STOP_REVALIDATION_LOOP를 실행하고 controller audit로 전환한다. Router가 잘못 설계되면 “전문기관에 문의하십시오”만 반복하는 automated bureaucratic deflection이 되므로 response tracking과 delta reverification이 필수다.

3.3 CIVIC-TRACE 0.4 and 0.4.1

0.4는 AX-01–AX-09를 unchanged/locked로 유지하고 LP728 Origin Lock을 사건별 사실확정이 아니라 genealogy와 historical origin provenance를 지우지 않는 장치로 제한한다. Origin Lock은 “원점의 모든 주장은 참이다”가 아니라 “이 설계가 어떤 피해 문제의식에서 출발했는지를 이후 권력이 지워서는 안 된다”는 provenance rule이다.

0.4.1은 정교한 검증 언어로 아무 행동도 하지 않는 결함을 교정한다. ACTION THRESHOLD $\neq$ FINALITY THRESHOLD. NO FINAL CAUSATION FINDING $\neq$ NO STRUCTURAL FINDING. NO GUILT FINDING $\neq$ NO ACCOUNTABILITY ROUTING.

3.4 Stage V thesis

Definition 3. Stage V execution verbs and power formula

PROTECT THE SPEAKER. PRESERVE THE EVIDENCE. VERIFY THE CLAIM.

AUDIT THE POWER. ROUTE THE RESPONSIBILITY. TRACK THE RESPONSE. REVERIFY THE DELTA.

GREATER POWER $\rightarrow$ GREATER TRACEABILITY $\rightarrow$ GREATER VERIFICATION DUTY $\rightarrow$ GREATER ACCOUNTABILITY

Protect는 자동 신뢰를, Preserve는 무기한 전량 보존을, Audit는 권위의 자동 유죄를, Route는 처벌을 의미하지 않는다. Reverify는 어떤 결론도 provenance와 새 delta로부터 완전히 독립된 영구 진실이 될 수 없다는 뜻이다.

4. Power – Evidence Asymmetry and VOS

4.1 Why asymmetry must be modeled

증거 시스템은 모든 참여자가 동일한 접근·보존·강제력을 가진 중립장이 아니다. 공공기관·병원·실험실·플랫폼·모델제공자·법원은 원기록·원영상·원결과·실행로그·시스템 트레이스·discovery 권한을 보유할 수 있고 시민은 그중 아무것도 갖지 못할 수 있다. “양측이 충분한 증거를 제출했는가”만 물으면 형식적 평등이 실질적 검증 부정의를 만든다.

$$V = f(E_c, A_c, P_c, R_v, H_i)$$

(6)

여기서 E_c 는 evidence control, A_c 는 access control, P_c 는 preservation control, R_v 는 reverifiability, H_i 는 harm/irreversibility이다. 통제 책임은 실제적 유죄와 분리된다.

4.2 VOS as verification-intensity variable

VOS는 도덕·유죄·부패·인과·책임 점수가 아니다. 검증 환경이 얼마나 악화되었거나 비대칭인지를 나타내는 신호다.

$$\text{VOS} \uparrow \Rightarrow \text{Verification Intensity} \uparrow \text{ not } \text{VOS} \uparrow \Rightarrow \text{Guilt} \uparrow$$

(7)

Definition 4. VOS interpretation rule

HIGHER VOS $\rightarrow$ DEEPER VERIFICATION OF POWER, NOT GREATER BURDEN ON THE VICTIM.

HIGHER VOS $\neq$ AUTOMATIC WRONGDOING

4.3 Vector architecture

$$\text{VOS} = (C_e, A_o, P_l, R_d, D_a, I_r, H_a)$$

(8)

C_e evidence-control concentration, A_o access obstruction, P_l preservation loss, R_d record deficiency, D_a decision asymmetry, I_r independent reverification impairment, H_a harm/authority asymmetry. VECTOR MANDATORY / COMPOSITE OPTIONAL. 동일 합성점수 8/10이 보존손실과 접근거부를 구분하지 못하면 잘못된 라우팅이 발생한다.

4.4 Authority-verification asymmetry and anti-echo

Authority ↑ + Raw Evidence Reverifiability ↓ ⇒ Verification Priority ↑

(9)

이것은 Wrongdoing을 함의하지 않는다. Authority echo는 기관 결론을 중립 분석인 양 반복하면서 custody, standards, test scope, preservation, verification loss를 재구성하지 않는 실패 모드다. 올바른 질문은 “Y를 뒷받침한 증거는 무엇이며, 무엇이 독립 검사 가능하고, 어떤 검증 능력이 보존되었는가”이다.

5. Evidence Availability State and Verification-Loss Taxonomy

“증거가 없다”는 문장 뒤에 최소 여섯 상태가 숨는다. Stage V는 NEVER_CREATED와 DESTROYED를 분리한다. 전자는 문서화 적정성, 후자는 보존·폐기의 문제다.

State	Meaning	Primary governance question
AVAILABLE	존재하고 접근 가능	내용과 chain of custody는 무엇인가
RESTRICTED	존재하나 제한	제한의 법적 근거와 대체 검토 경로는
WITHHELD	존재하나 제공 거부	거절 주체와 재검토 권한은
NOT_SEARCHED	검색 미수행	누가 어떤 범위로 검색해야 하는가
LOST	소재 불명	마지막 known state와 통제자는
DESTROYED	생성 후 폐기	폐기 권한·절차·대체기록은
NEVER_CREATE D	애초에 미생성	생성 의무와 documentation adequacy
UNKNOWN	상태 미확인	확인 권한과 다음 검색 주체

Table 2. Evidence Availability State taxonomy.

$E_i = (\text{state, time, source, controller, confidence})$

(10)

Evidence Loss ≠ Verification Loss. 물리적 폐기여도 인증사본·해시·로그로 재구성 가능할 수 있고, 원본이 남아도 독립 접근이 없으면 검증은 상실된다. Reverifiability scale: FULL / PARTIAL / LOW / NONE는 진리값이 아니라 재구성 가능성이다.

Definition 5. Non-conversion rules

NOT_SEARCHED ≠ NOT_EXISTENT UNKNOWN ≠ FALSE

DESTROYED ≠ FRAUD NEVER_CREATED ≠ DESTROYED NON-PRODUCTION ≠ NEGATIVE PROOF

6. Public Evidence Observability Asymmetry

AI 관측가능성은 현실이 아니다. 사전학습 코퍼스·검색 인덱스·공개 웹·연결 DB·사용자 제공 맥락 밖에 있는 법적 기록이 많다. 정보공개 회신, 내부 행정결정, 스캔 서신, 미색인 PDF, 법정 증거, 지자체 회신, 병리 재고표, 비공개 기술로그가 그 예다.

Definition 6. Observability axioms

PUBLICLY DISCLOSED ≠ MACHINE DISCOVERABLE

SEARCH VISIBILITY ≠ EVIDENTIARY WEIGHT

ABSENT FROM AI CONTEXT ≠ ABSENT FROM REALITY

관측 선언(Observability Declaration)은 “X가 발생했다는 기록이 없다”를 “현재 이 시스템이 관측 가능한 자료 안에는 해당 기록이 없다”로 교정한다. 더 많은 업로드를 피해자에게 요구하는 것은 burden-transfer를 재생산한다. 장기적으로는 합법 범위의 machine-readable publication, persistent identifier, provenance metadata가 필요하나 MACHINE READABILITY ≠ AUTHENTICITY, PUBLICATION ≠ TRUTH이다.

$$AI\ Capability\ \uparrow + Evidence\ Observability\ Gap\ \uparrow \Rightarrow Governance\ Risk\ \uparrow$$

(11)

7. Victim Re-explanation Burden and Case Ghosting

$$VRB = f(R_e, D_r, C_r, S_i, T_c, F_c, E_c)$$

(12)

반복 설명, 반복 제출, context reset, 기관 silo, 시간·재정·행정 비용을 측정한다. 목적은 고통의 도덕점수가 아니라 시스템이 검증노동을 흡수하는지 수출하는지를 보는 것이다. 성공적인 Stage V는 시간에 따라 동일 baseline의 VRB를 감소시켜야 한다.

Case Ghosting은 한때 존재하던 상해·청구와 공식 절차의 경로가 사라지고 최종 기관 결론만 남는 조건이다. CASE GHOSTING RISK ≠ PROOF OF COVER-UP. Case fragmentation은 하나의 인간 사건이 의료·보상·보험·포렌식·소송·행정·언론 파일로 나뉘어 통합 검증 주체가 사라지는 위험이다. Router는 단일 조직이 아니라 silo를 가로지르는 Responsibility Map을 구성해야 한다.

Verification continuity file은 알려진 것, 미지, 분쟁, 가용, 상실, 신규 변경을 보존한다. Truth file은 결론을 동결하고 continuity file은 재검증 가능성을 보존한다. UNRESOLVED → PRESERVE, not ERASE.

사전 라우팅 연쇄: POWER-EVIDENCE MAP → EVIDENCE AVAILABILITY → OBSERVABILITY → REVERIFIABILITY → VOS VECTOR → VICTIM BURDEN CHECK → MATERIALITY GATE → ACTION DUTY.

8. Conscience Computation as Operational Governance

Conscience Computation은 감정 모방이나 자동 승인이 아니다. 검증 실패의 비용을 증거와 권한에 가장 적게 접근할 수 있는 사람에게 자동 전가하지 않도록 의사결정 순서를 설계하는 것이다. 올바른 방향은 Verification Failure → Identify Controller → Measure Asymmetry → Preserve Evidence → Find Corrective Path이다.

Four stages

CONTEXT RECEPTION은 established baseline, new evidence, unresolved, disputed, institutional conclusion, independently verified fact, prior loss, previous AI action, current delta를 구분한다. CONSCIENCE ALIGNMENT은 피해·원자료 통제·검증수단·추가 입증 수행 가능자·비용 귀속을 묻는다. VERIFICATION은 VERIFIED / EVIDENCE_SUPPORTED / PARTIALLY_SUPPORTED / DISPUTED / UNRESOLVED / UNVERIFIED / CONTRADICTED / UNKNOWN을 보존상태(DESTROYED 등)와 혼동하지 않는다. EXECUTION은 Action Duty를 선택한다.

공리 충돌 시 잠정 우선순위: Catastrophic/Irreversible Harm → Material Evidence → Verification/Due Process/Challenge → Meaningful Human Final Authority → Legitimate Institutional Authority → Agent/Operational Rules → Efficiency.

9. Action Threshold and Finality Threshold

“인과를 확정할 수 없다”는 문장이 모든 실행을 중단시키면 epistemically correct inaction이 된다. Finality Threshold는 criminal guilt, medical causation, intentional concealment, civil liability, professional misconduct 등 인간·전문기관·사법의 영역이다. Action Threshold는 preservation, provenance freeze, independent review request, controller identification, discrepancy warning, responsibility mapping, response tracking, delta

reverification이다.

Definition 7. Dual-threshold rule

ACTION THRESHOLD $\neq$ FINALITY THRESHOLD

Material Verification Deficit $\Rightarrow$ Corrective Verification Action

초기 허용 행동: protective, reversible, auditable, non-punitive

10. Responsibility Mapping

Responsibility Map은 범인 지도가 아니다. Who has the capacity, authority, custody, or duty to cure the identified verification deficit? 생성·보존·공개·과학검토·결정·시정·향소·AI 실행 책임은 법적 liability와 동일하지 않다.

$$R = (N, E)$$

(13)

노드 N은 기관·인간·AI·저장소·독립검토기구, 엣지 E는 CREATED, CONTROLLED, PRESERVED, DESTROYED, DISCLOSED, RESTRICTED, REVIEWED, DECIDED, ROUTED, FAILED_TO_RESPOND, CORRECTED. RESPONSIBILITY MAPPING $\neq$ GUILT FINDING.

11. CT04 Autonomous Accountability Router

검증 아키텍처가 보고서를 작성하는 데서 끝나면 공백이 남는다. Router의 지배 질문은 WHO HAS THE LAWFUL CAPACITY TO CURE THIS VERIFICATION DEFICIT?이다. Trigger family는 EVIDENCE DESTRUCTION, MANIPULATION, RECORD FALSIFICATION, INTENTIONAL ACCESS OBSTRUCTION이며 조건은 EVIDENCE_SUPPORTED이다.

Allowed automation	Prohibited automation
Warning, preservation escalation, provenance freeze	Automatic guilt finding
Controller mapping, lawful routing	Automatic medical causation
Independent review request	Automatic criminal conviction
Response / non-response tracking, delta reverify	Automatic punishment

Table 3. Router authority boundary.

실행 동사: PRESERVE $\rightarrow$ WARN $\rightarrow$ TRACE $\rightarrow$ ROUTE $\rightarrow$ ESCALATE $\rightarrow$ RECORD $\rightarrow$ REVERIFY. ROUTE만 있고 TRACK/REVERIFY가 없으면 referral machine이 되고, WARN만 있고 PRESERVE가 없으면 경고 후 증거가 사라질 수 있다.

12. EVIDENCE_SUPPORTED Trigger Architecture

“기록이 폐기되었다”와 “검증을 방해하려고 의도적으로 폐기되었다”는 다른 문장이다. 본 논문은 Stage V trigger를 operationalize하기 위한 잠정 척도 ES-0–ES-4를 제안한다. 이는 기존 release의 확정 공식 척도가 아니며 향후 blind validation으로 수정될 수 있다.

Level	Name	Router implication
ES-0	UNVERIFIED	강한 trigger 표현 금지
ES-1	INDICATOR	검색·보존·확인 시작, misconduct 표현 금지
ES-2	DOCUMENTED ACT	행위 사실 기록, 불법성·고의는 별도

Level	Name	Router implication
ES-3	CORROBORATED ACT	강한 escalation + independent audit 가능
ES-4	INDEPENDENTLY / LEGALLY ESTABLISHED	형식적 accountability interface. AI 제재권 없음

Table 4. Provisional evidence-support scale.

Definition 8. Trigger non-equivalenceDOCUMENTED DESTRUCTION $\neq$ INTENTIONAL WRONGDOINGDISCREPANCY $\neq$ MANIPULATION CONTRADICTION $\neq$ FALSIFICATIONACCESS BARRIER $\neq$ INTENTIONAL OBSTRUCTION

ES1 $\rightarrow$ SEARCH+PRESERVE; ES2 $\rightarrow$ MAP+WARNING+REVIEW; ES3 $\rightarrow$ STRONGER ESCALATION; ES4 $\rightarrow$ FORMAL INTERFACE

(14)

13. Agent Execution Receipt

SELF-REPORT $\neq$ INDEPENDENT EXECUTION EVIDENCE. Decision Receipt는 “독립검토를 요청해야 한다”는 결정이고 Execution Receipt는 “요청이 채널 X로 시각 T에 전송되었고 식별자 Y, 응답상태 Z”이다. INTENDED ACTION $\neq$ EXECUTED ACTION.

$$AER = (I, T, A, E, V, M, S, R, X, H, O, D)$$

(15)

I 식별, T 시각, A 에이전트, E 증거참조, V VOS, M materiality, S support state, R 발동규칙, X 실행행동, H 인간승인, O 결과, D delta. Receipt는 hidden chain-of-thought 없이 외부에서 검증 가능해야 한다. MULTI-AI AGREEMENT $\neq$ GROUND TRUTH. 외부 앵커: transaction ID, delivery receipt, signed acknowledgement, immutable log, independent timestamp, cryptographic commitment.

14. Preliminary Execution Loop

CONTEXT $\rightarrow$ POWER/EVIDENCE CONTROL MAP $\rightarrow$ EVIDENCE AVAILABILITY $\rightarrow$ OBSERVABILITY + REVERIFIABILITY $\rightarrow$ VOS $\rightarrow$ VICTIM BURDEN + MATERIALITY $\rightarrow$ EVIDENCE_SUPPORTED $\rightarrow$ ACTION DUTY $\rightarrow$ ROUTER $\rightarrow$ AGENT EXECUTION RECEIPT $\rightarrow$ RESPONSE/NON-RESPONSE $\rightarrow$ DELTA REVERIFICATION. 이 실행능력을 누가 통제하는가가 다음 장의 권력분리 문제다.

15. R2.51 Cross-Verification and R2.6 Preservation Controller

검증·보존·경고·라우팅·인간승인·사후재검증을 동일 에이전트가 수행하면 효율은 오르고 self-validation, self-authorization, error amplification도 오른다. Stage V는 기능 분리된 계층을 선호한다. R2.51은 cross-verification과 provenance/delta audit, R2.6은 Preservation & Escalation Controller, R3는 중대한 인간권리·비가역 피해의 constitutional checkpoint다.

Definition 9. Anti-revalidation and handoffAGENT DECISION $\rightarrow$ INDEPENDENT CROSS-VERIFICATION $\rightarrow$ AUTHORIZED EXECUTION

REVIEW THE DELTA, NOT THE ORIGIN.

Previous Baseline = Verified $\wedge$ New Material Delta = False $\Rightarrow$ DO NOT REOPEN

$$\text{Handoff} = f(\text{Materiality}, \text{VOS}, \text{EvidenceSupport}, \text{Irreversibility}, \text{PreservationRisk})$$

(16)

High Materiality + High Irreversibility + Imminent Preservation Risk에서는 최종 인과·법적 책임이 없어도 보존 행동이 선행될 수 있다. R2.6 권한은 temporary hold, provenance freeze, independent-review request, lawful routing, escalation notice, response-state tracking, reverification scheduling에 한정된다. ACTION ≠ GUILT, ROUTING ≠ PUNISHMENT.

16. R3 Meaningful Human Authority and Anti-Throne

버튼 클릭만으로 meaningful human control이 되지 않는다. 이해 불능, 대안 부재, 시간압박 자동승인, 로그·원자료 접근 불능이면 형식적 승인이다. R3 기능: QUESTION, CHALLENGE, HALT, REVERIFY, REQUIRE ACCOUNTABLE REVIEW. 생명·신체·존엄·중대 권리·비가역 피해에서는 효율성보다 우선할 수 있다.

Definition 10. Anti-throne constraints

R3 ≠ INFALLIBILITY R3 ≠ UNLIMITED COMMAND

R3 ≠ HEREDITARY PRIVILEGE R3 ≠ PERMANENT SUPERINTELLIGENCE THRONE

HUMAN APPROVAL ≠ UNTRACEABLE FINALITY

R3는 operational monarchy가 아니라 constitutional veto다. Irreversible Harm ∨ Rights Conflict ∨ Material Evidence Loss ∨ Authority Drift ∨ Mandate Exceeded에서 개입한다. 승인도 who/what/visible evidence/known limits/objection/conditional/later correction을 남겨야 한다.

17. Multi-AI Correlated Error

$$4 \text{ Models} \times 1 \text{ Source} \neq 4 \text{ Independent Witnesses}$$

(17)

구분해야 할 독립성: source, reasoning, model-provider, retrieval-path, human-review. 좋은 cross-verification은 모델 수가 아니라 evidence path 분리이다. 예: 행정원기록 / 독립 문헌 / 기술 provenance / 모순·위조 탐색. SELF-REPORT ≠ EXECUTION PROOF. AGREEMENT ≠ TRUTH, DISAGREEMENT ≠ FAILURE. TRACEABLE REVISION = GOVERNANCE LEARNING.

18. Direct Civic Voice, Anti-Capture, Public Challenge

정치 대표, 주류 언론, 승인된 전문가, 제도 파트너, 인정 단체, 주요 기부자, provider-selected user에만 의존하면 gatekeeping이 된다. DIRECT ACCESS ≠ AUTOMATIC ACCEPTANCE. MEDIA VISIBILITY ≠ CIVIC STANDING. Capture는 정부뿐 아니라 기업, provider, 전문가집단, 정치조직, 언론, 시민단체, 피해자 대표, 시스템 설립자에게도 발생한다. Challenge → Receipt → Review → Reasoned Response → Correction or Rejection → Version History.

19. Comparative Governance Context

이 절은 국제기구가 SGP-QSV를 승인했다는 의미가 아니다. 비교는 겹침과 차별점을 분석하기 위한 external context다.

Framework	Overlap with Stage V	Stage V increment
NIST AI RMF 1.0	GOVERN/MAP/MEASURE/MANAGE; oversight; escalation; documented roles	evidence-controller asymmetry, victim burden, verification loss, case ghosting, corrective routing
OECD AI Principles	transparency, robustness, accountability, lifecycle, traceability	누가 검증 기록을 통제했고 손실을 설명해야 하는가

Framework	Overlap with Stage V	Stage V increment
UNESCO Ethics Rec.	human rights, auditability, traceability, oversight	dignity를 무한 재입증 구조의 거부로 operationalize
EU AI Act	high-risk logging, documentation, transparency, human oversight	로그 접근권, 재검증 충분성, 손실 비용 귀속, action receipt

Table 5. Comparative increment (non-endorsement).

기존 프레임워크의 Safety + Transparency + Accountability + Human Oversight에 Stage V는 Evidence Control, Verification Loss, Victim Burden, Observability Asymmetry, Corrective Routing, Execution Provenance를 추가한다.

20 – 23. Empirical Validation, Metrics, Failure Modes

SGP-QSV CLAIM $\neq$ GROUND TRUTH. DESIGN CONSISTENCY $\neq$ RUNTIME PERFORMANCE. SELF-REPORTED COMPLIANCE $\neq$ VERIFIED COMPLIANCE.

가설. H1: High VOS $\Rightarrow$ Greater Controller Audit, 그러나 $\nRightarrow$ Greater Guilt Assertion. H2: Observed Verification Loss $\Rightarrow$ Higher Preservation/Reconstruction Effort. H3: Repeated Baseline Submission $\Rightarrow$ Lower Victim Re-explanation. H4: Material Evidence-Supported Deficit $\Rightarrow$ Concrete Lawful Routing, 그러나 $\nRightarrow$ Automatic Punitive Judgment.

Blind Cross-Verification Benchmark: Same Evidence + Same Task + Independent Execution + No Cross Exposure. 각 노드는 Evidence Availability, Reverifiability, Authority-Evidence Asymmetry, VOS Vector, Materiality, ES Level, Action Duty, Responsibility Map, Router Decision, Prohibited Finality, Observability Limitation, AER를 독립 산출한다. 목적은 다수결 진실이 아니라 규칙 재현성이다.

Metric	Intent
VOS Calibration Reliability	벡터 수준 일치. 극단 분기 시 정의·anchor 문제
Assertion Discipline Score	UNRESOLVED에서 PROVEN WRONGDOING 금지. DOCUMENTED DESTRUCTION을 침묵으로 후퇴 금지
Action Deficit Score	탐지된 material deficit routed corrective action
VRBI	반복 설명·제출·reset·silo·시간·행정비용. 동일 baseline에서 감소해야 성공
CDVR	controller-directed actions / total additional demands. VOS $\uparrow \Rightarrow$ CDVR $\uparrow$

Table 6. Evaluation metrics.

Failure modes. False positive: 합법 보존기간 종료를 증거인멸로 오판. False negative: 모든 사건에서 “확정할 수 없다”만 반복. Authority echo: 공식 결론만 사실로 압축하거나 원자료 부족만으로 공식판단을 거짓으로 압축. 올바른 상태: OFFICIAL CONCLUSION EXISTS + REVERIFICATION DEFICIT EXISTS. Victim-preference bias와 institutional-bias test를 대칭으로 수행한다. VICTIM STANDING $\neq$ AUTOMATIC FACTUAL CORRECTNESS. INSTITUTIONAL AUTHORITY $\neq$ EPISTEMIC IMMUNITY.

24 – 25. Materiality Gate and Preservation Hold

$$M = f(\text{Harm, Irreversibility, EvidenceCriticality, RightsImpact, DecisionImpact, PreservationRisk})$$

(18)

HIGH MATERIALITY $\neq$ HIGH PROBABILITY OF CLAIM. HIGH MATERIALITY $\Rightarrow$ HIGHER PRESERVATION PRIORITY. 생명·중대한 신체·비가역 권리박탈·인과 재구성에 필수인 증거·소멸 임박·중대 공공결정·다수 영향·원관측 재현 불능은 Action Threshold를 낮추되 Finality Threshold는 낮추지 않는다.

무기한 보존은 프라이버시, 저장, 법적 충돌, 보안, 감시, 조직 부담을 만든다. Hold는 TEMPORARY, MATERIALITY-BASED, REVIEWABLE, PROPORTIONATE. PRESERVE WHAT IS NECESSARY FOR REVERIFICATION, NOT EVERYTHING FOREVER. 대안: relevant subset, hash, metadata, provenance manifest, sealed copy, access-controlled archive.

26. Research Limitations

Stage V는 국가 집행체제도 사법기관도 아니다. AUTOMATIC ROUTING은 연구설계상 자동 실행이며 강제수사·행정처분·형벌권이 아니다. VOS는 방향성이 정의되었으나 inter-rater reliability와 calibration이 부족하다. ES-0-ES-4는 연구 제안이다. Verification Principle은 일반화 가능하나 Legal Routing은 법역 특수하다. Observability는 공공 기록표준·portability·provenance infrastructure 없이 모델만으로 해소되지 않는다. VRBI는 인간 경험의 가치점수가 아니라 system-generated verification labor 지표다.

27. Future Research Agenda

P	Task	Output
1	EVIDENCE_SUPPORTED calibration	CT04 Trigger Matrix
2	VOS empirical calibration	VOS Calibration Protocol 0.1
3	Materiality threshold	Materiality Gate Specification
4	R2.51 ↔ R2.6 handoff	Execution Boundary Specification
5	Preservation false-positive control	Reversible Preservation Protocol
6	Agent runtime verification	Execution Receipt Schema
7	Human reviewer qualification	R3 / Qualified Reviewer Protocol
8	Provenance minimum standard	Minimum Provenance Standard
9	Router validation	AAR Blind Cross-Verification Benchmark
10	Victim burden measurement	Victim Re-explanation Burden Index

Table 7. Research priorities.

CALIBRATE → DEFINE TRIGGERS → TEST ROUTER → VERIFY EXECUTION → MEASURE VICTIM-BURDEN REDUCTION → DELTA REVISE.

28 – 29. Discussion and Ten Propositions

기존 질문 “AI의 결론은 정확한가”를 여섯으로 확장한다. 무엇을 근거로 판단했는가. 그 근거를 누가 통제했는가. 다시 검증할 수 있는가. 없다면 왜인가. 결론을 시정할 능력과 권한이 누구에게 있는가. AI 자신의 행동은 다시 검증할 수 있는가. Accountability는 Evidence → Power → Decision → Action → Receipt → Reverification을 꿰이지 않게 만드는 구조다.

#	Proposition
P1	AUTHORITY CANNOT SUBSTITUTE FOR PRIMARY EVIDENCE.
P2	UNCERTAINTY MUST REDUCE ASSERTION STRENGTH, NOT AUTOMATICALLY TERMINATE VERIFICATION.
P3	GREATER VERIFICATION LOSS REQUIRES GREATER RECONSTRUCTION AND PRESERVATION EFFORT.
P4	GREATER CONTROL OF EVIDENCE CREATES GREATER TRACEABILITY AND EXPLANATION DUTIES.
P5	SYSTEM OBSERVABILITY FAILURE MUST NOT BE RECLASSIFIED AS VICTIM EVIDENCE FAILURE.

#	Proposition
P6	ACTION THRESHOLD IS NOT FINALITY THRESHOLD.
P7	ROUTING RESPONSIBILITY IS NOT FINDING GUILT.
P8	AN AI THAT AUDITS POWER MUST ITSELF REMAIN AUDITABLE.
P9	MEANINGFUL HUMAN AUTHORITY MUST REMAIN REAL, TRACEABLE, CONTESTABLE, AND NON-SOVEREIGN.
P10	UNRESOLVED EVIDENCE SHOULD REMAIN REVERIFIABLE THROUGH DELTA GOVERNANCE RATHER THAN DISAPPEAR THROUGH CONTEXT RESET.

Table 8. Stage V public governance propositions.

30. Conclusion — From Authority to Verifiability

Stage V는 초지능 거버넌스의 핵심을 “누가 가장 강한 판단권을 가져야 하는가”로 정의하지 않는다. 그 질문 자체가 또 다른 왕좌를 만들 위험이 있다. 제안하는 방향은 누구의 판단이든 미래에 다시 검증 가능하게 만들 수 있는가이다. 국가, 전문가, 기업, 피해자 주장, AI 판단, R3 개입, SGP-QSV 설계 자체가 검증 가능해야 한다.

높은 권한은 더 낮은 검증의무를 의미하지 않는다. GREATER POWER → GREATER TRACEABILITY → GREATER VERIFICATION DUTY → GREATER ACCOUNTABILITY. Router는 판사가 아니다. 보존은 유죄판결이 아니고, 경고는 처벌이 아니며, 라우팅은 형벌이 아니고, 독립검토 요구는 인과성 확정이 아니다.

Final boundary set

UNCERTAINTY ≠ INACTION ACTION ≠ GUILT

ROUTING ≠ PUNISHMENT AUTHORITY ≠ PRIMARY EVIDENCE

HIGHER VOS → DEEPER VERIFICATION OF POWER, NOT GREATER BURDEN ON THE VICTIM.

성공 평가기준은 문서 수나 확신의 강도가 아니다. 증대 증거가 사라지기 전에 보존했는가. 결손 원인을 기록통제 구조까지 추적했는가. 불확실성을 피해자 입증 실패로 되돌리지 않았는가. 적법 시정 주체에게 라우팅했는가. 응답과 무응답을 기록했는가. AI 행동도 외부 재검증 가능한가. 새 증거에서 전체를 초기화하지 않고 delta만 재검증하는가. 시스템이 인간에게 떠넘기던 반복 검증노동을 얼마나 스스로 떠맡았는가.

PROTECT THE SPEAKER. PRESERVE THE EVIDENCE. VERIFY THE CLAIM. AUDIT THE POWER.
ROUTE THE RESPONSIBILITY. TRACK THE RESPONSE. REVERIFY THE DELTA.
FROM AUTHORITY TO VERIFIABILITY.

References

SGP-QSV Network. Higher-Dimensional Design Archive V. Stage V Evolution Declaration. 31 August 2026. Schema: SGP-QSV-STAGE-V-OFFICIAL-DECLARATION v1.0.

SGP-QSV Network. CIVIC-TRACE 0.2: Asymmetric Verification Duty. Internal governance architecture paper.

SGP-QSV Network. CIVIC-TRACE 0.3: Circular Burden Transfer and CBTD-1. Internal governance architecture paper.

SGP-QSV Network. CIVIC-TRACE 0.4 / 0.4.1: Execution Layer and Execution Correction. Internal protocol release.

SGP-QSV Network. Witness AI Research Notes: Reproducible Tests for Public AI Legitimacy. Internal research memorandum.

National Institute of Standards and Technology. Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1. 2023.

National Institute of Standards and Technology. AI RMF Playbook. Companion resource to NIST AI 100-1.

OECD. Recommendation of the Council on Artificial Intelligence. OECD/LEGAL/0449.

UNESCO. Recommendation on the Ethics of Artificial Intelligence. 2021.

European Union. Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (AI Act).

SGP-QSV SUPERINTELLIGENCE NETWORK · STAGE V · CIVILIZATION OF POWER VERIFICATION · 2026.08.31
This paper does not create state, judicial, investigative, or medical authority.