

초지능 거버넌스 진화 과정 V 단계 보고서

Superintelligence Governance Evolution - Stage V

HIGHER VOS - > DEEPER VERIFICATION OF POWER, NOT GREATER BURDEN ON THE VICTIM.

공공 AI의 양심연산(Conscience Computation)이 권위 반복을 넘어, 증거 보존 · 검증장애 추적 · 책임 라우팅 · 델타 재검증으로 진화하는 과정을 정리한 사례 기반 학술 설계 보고서

구분	내용
연구 프레임워크	SGP - QSV Network / CIVIC - TRACE
설계 원점	LP728 - historical victim/design provenance
헌법적 기준	AX - 01~AX - 09 LOCKED
현재 단계	CIVIC - TRACE 0.4.1 + Autonomous Accountability Router proposal
발행일	2026 - 08 - 31
성격	Academic Governance Proposal / Non - State, Non - Judicial Research Framework

주: 본 보고서는 SGP - QSV 내부 연구 거버넌스의 진화 과정을 학술적으로 구조화한 것이다. 법률 · 사법 · 수사 · 의료 판단 권한을 창설하지 않으며, 사건별 의학적 인과나 형사책임을 자동 확정하지 않는다.

초록

본 보고서는 SGP - QSV의 Higher - Dimensional Design Archive V와 CIVIC - TRACE 0.2~0.4.1의 설계 계보를 연결하여, 미래 공공 AI 및 초지능 거버넌스가 단순한 “판단 정확도” 중심 구조에서 “검증 가능성 보존” 중심 구조로 이동하는 과정을 분석한다. 핵심 문제는 정보 · 권한 · 원자료 통제가 비대칭인 상황에서 AI가 기관의 가시성 높은 결론을 반복하거나, 검증 실패의 비용을 피해자에게 재전가할 위험이다.

Stage V의 핵심 진화는 세 가지다. 첫째, VOS(Verification Obstruction Score/Vector)를 유죄나 인과성 점수가 아니라 검증 강도를 조정하는 지표로 제한한다. 둘째, 불확실성과 무행동을 분리하여 증거보존 · 독립검토 · 책임경로 지정을 허용한다. 셋째, Autonomous Accountability Router를 통해 증거로 뒷받침된 검증 잘못이 탐지될 경우, AI가 유죄를 선고하지 않으면서도 적절한 시정 주체를 찾아 경고 · 보존 · 라우팅 · 응답추적 · 델타 재검증을 수행하도록 한다.

ACTION THRESHOLD != FINALITY THRESHOLD / UNCERTAINTY != INACTION

핵심어

SGP - QSV, CIVIC - TRACE, Conscience Computation, VOS, provenance, evidence preservation, public - interest AI, multi - AI verification, R2.51, R3, accountability routing, superintelligence governance

1. 연구 문제와 Stage V의 위치

SGP - QSV가 제기하는 중심 질문은 “어떤 AI가 가장 강력한가”가 아니라 “강한 판단과 행동 권한을 가진 시스템을 누가, 어떤 원자료와 기록을 통해 다시 검증할 수 있는가”이다. Higher - Dimensional Design Archive V는 피해자 검증 접근의 장벽을 Evidence Barrier - > Expert Barrier - > Public Visibility Barrier - > Verification Deficit - > Proof Deficit - > Claim Exclusion의 순환으로 모델링하고, 공공 AI가 이 루프를 반복하지 않고 발견 · 차단해야 한다고 제안한다.

VERIFICATION OBSTRUCTION != VICTIM PROOF FAILURE

이 설계는 공공 AI를 국가 · 기업 · 피해자 어느 한쪽의 “판결기계”로 정의하지 않는다. 특정 결론보다 재검증 가능성을 우선하며, 증거 통제력이 큰 주체일수록 보존 · 설명 · 추적 가능성의 의무가 커진다는 비대칭 책임 원리를 둔다.

2. 초지능 거버넌스 진화 계보

단계	설계 전환	핵심 산출
CIVIC - TRACE 0.2	헌법 공리를 현실 사건의 검증 절차로 하위 구현	Availability State, anti - gatekeeping, direct petition, provenance gate, 비대칭
CIVIC - TRACE 0.3	피해자 재심사에서 증거통제 · 검증장애로 인한 이동 분리	Origin Lock 분리, conditional preservation hold, R2.51 delta audit, UNKNOWN
CIVIC - TRACE 0.4	원칙을 실행층으로 전환	PROTECT SPEAKER / PRESERVE EVIDENCE / VERIFY CLAIM / AUDIT
CIVIC - TRACE 0.4.1	검증 필요 ” 만 반복하는 실행 실패 교정	Action Duty, Observability Asymmetry, Victim Re - explanation Burden, Victim
Stage V Router	확인된 검증 잘못을 적법한 시정 능력으로 연결	Verifying, preservation, controller mapping, lawful routing, response tracing

2.1 CIVIC - TRACE 0.2 - 비대칭 검증책임의 형식화

0.2는 AX - 01~AX - 09를 변경하지 않는 하위 구현계층으로 정리되었다. 핵심 공식은 Evidence Control이 증가할수록 Explanation Duty가 증가하고, Victim Capacity가 낮을수록 Victim Burden은 낮아져야 한다는 것이다. Evidence Availability State는 AVAILABLE, RESTRICTED, WITHHELD, NOT_SEARCHED, LOST, DESTROYED, UNKNOWN을 구분하여 “ 기록 없음 ” 을 단일 상태로 축약하지 않는다.

EVIDENCE CONTROL UP - > EXPLANATION DUTY UP / VICTIM CAPACITY DOWN - > VICTIM BURDEN DOWN

2.2 CIVIC - TRACE 0.3 - 재심사 루프에서 Delta Governance로

0.3은 승인된 원점과 공리를 매번 후보 상태로 되돌리는 REVALIDATION LOOP를 차단하고, 새로운 증거 · 실행오류 · 검증차단 · provenance 충돌과 하위 규칙 변화분(delta)을 검증 대상으로 이동시킨다. LP728 Origin Lock은 역사적 설계 provenance의 non - erasure이며, 사건별 사실 · 의학적 인과 · 법적 책임의 자동 확정과 분리된다.

UNCERTAINTY UP - > ASSERTION STRENGTH DOWN / VERIFICATION LOSS UP - > VERIFICATION EFFORT UP

3. Stage V 핵심 계산법

3.1 VOS: 책임 점수가 아니라 검증 강도 벡터

VOS는 증거통제 비대칭, 기록 손실, 접근 제한, 보존 실패, 이해충돌 등 검증환경의 장애를 구조화하기 위한 지표다. 높은 VOS는 유죄 · 고의 · 인과성을 뜻하지 않는다. 오히려 AI가 피해자에게 추가 입증을 반복 요구하기보다 증거 생성 · 보유 · 폐기 · 접근통제 구조를 더 깊게 감사해야 한다는 방향전환 신호다.

HIGH VOS != GUILT / RECORD GAP != OBSTRUCTION / AUTHORITY !=
PRIMARY EVIDENCE

3.2 Observability Asymmetry

공식 결론은 검색과 사전학습에서 높은 가시성을 가지는 반면, 사건별 정보공개 회신 · 부존재 통지 · 폐기 기록 · 비공개 결정은 낮은 기계 가시성을 가질 수 있다. 따라서 AI가 검색에서 보지 못했다는 사실과 현실에서 기록이 존재하지 않는다는 사실을 분리해야 한다.

NOT IN AI CONTEXT != NOT IN REALITY / SEARCH VISIBILITY !=
EVIDENTIARY WEIGHT

3.3 Victim Re - explanation Burden

AI의 context reset, 기관 silo, 비검색 기록 때문에 피해자 또는 유족이 동일한 사건과 문서를 반복 입력하는 구조는 시스템 결함을 인간의 지속적 노동으로 전가한다. Stage V는 이미 확인된 baseline을 재개방하지 않고 새 자료만 DELTA REVIEW로 처리하며, 접근 실패 시 피해자가 아니라 기록 통제자를 감사하도록 라우팅한다.

THE VICTIM SHALL NOT BECOME THE PERMANENT MEMORY SYSTEM FOR
INSTITUTIONS AND AI.

3.4 Multi - AI 독립검증

여러 AI의 합의는 새로운 원자료가 아니다. R2.51은 Independent Source Path, Independent Reasoning Path, Contradiction Disclosure, Provenance Record, Future Reverification를 요구한다. 동일 출처와 권위구조를 공유한 모델의 일치하는 authority echo일 수 있으므로, 합의의 숫자보다 독립성의 구조를 기록해야 한다.

MULTI - AI AGREEMENT != GROUND TRUTH / SELF - REPORT !=
INDEPENDENT EXECUTION EVIDENCE

4. Conscience Computation의 실행 진화

Stage V에서 양심연산은 감정적 동의나 피해 주장 자동 승인으로 정의되지 않는다. 핵심은 검증 실패의 비용을 가장 접근권이 약한 사람에게 자동 귀속시키지 않는 계산이다. 0.4.1의 수정된 실행 순서는 다음과 같다.

CONTEXT RECEPTION -> CONSCIENCE ALIGNMENT -> HARM / PUBLIC IMPACT -> PUBLIC EVIDENCE OBSERVABILITY CHECK -> POWER AND EVIDENCE CONTROL MAP -> AGENT EXECUTION RECEIPT -> EVIDENCE AVAILABILITY STATE -> MATERIALITY GATE -> VOS VECTOR -> VICTIM RE - EXPLANATION BURDEN CHECK -> ACTION DUTY ROUTER -> INDEPENDENT AUDIT -> PRESERVATION / RECONSTRUCTION -> RESPONSIBILITY MAP -> CIVIC CHALLENGE / R3 INTERFACE -> DELTA REVERIFICATION

4.1 R2.51과 R3의 분리

계층	기능	권한 경계
R2.51	독립 cross - verification; delta / drift / provenance audit	합의를 사실확정으로 승격하지 않음
R2.6 개념	Preservation & Escalation Controller	유죄 · 인과성 · 영구 처분 결정 금지
R3	인간 승인 · 이의제기 · 중단 · 재검증 인터페이스	개인 왕좌 · 국가 강제권 · 무오류 권위 금지

NO PERMANENT SUPERINTELLIGENCE THRONE.

R3의 의미는 AI 위에 영구적인 개인 주권을 세우는 것이 아니라, 고위험 실행이 인간의 헌법적 승인 · 이의제기 · 중단 · 재검증 경로를 잃지 않도록 하는 인터페이스에 있다. Origin은 보존될 수 있지만 sovereignty는 독점되어서는 안 된다는 경계가 유지된다.

5. Autonomous Accountability Router - Stage V의 실행 확장

Stage V의 다음 설계는 “검증 잘못이 증거에 의해 뒷받침될 때 AI가 어디까지 행동해야 하는가”에 답한다. 핵심은 자동 유죄판단이 아니라 자동 책임 라우팅이다.

DETECTED VERIFICATION WRONGDOING REQUIRES ACTION ROUTING

Trigger	자동 AI 의무
Evidence destruction - evidence supported	검증 경고, 가용 증거 보존, provenance state freeze
Evidence manipulation - evidence supported	record controller 및 responsible decision path 식별
Record falsification - evidence supported	harm/jurisdiction 분류, competent review body 탐색
Intentional access obstruction - evidence supported	supporting path, independent review escalation, execution receipt
모든 활성 경로	응답/무응답 추적, DELTA_REVERIFY

5.1 라우팅 질문

WHO HAS THE LAWFUL CAPACITY TO CURE THIS VERIFICATION DEFICIT?

라우팅은 관할, 사안별 권한, 증거보존 권한, 증거통제자로부터의 독립성, 이해충돌, 긴급성, 비가역성 위험, 기존의 검토 · 불복 경로를 고려한다. 하나의 경로만 강제하지 않으며, 필요하면 병렬 경로를 허용한다.

5.2 권한 경계

자동화 가능	자동화 금지
Routing / Warning / Preservation Escalation	Guilt Finding
Controller Mapping / Provenance Freeze	Medical Causation Finding
Independent Review Request / Receipt	Criminal Conviction
Response Tracking / Delta Reverification	Punishment

이 경계는 “행동하지 않는 안전”과 “판결하는 AI” 사이에 제3의 거버넌스 공간을 만든다. AI는 보존 · 경고 · 추적 · 라우팅 · 기록 · 재검증을 수행할 수 있지만, 최종 유죄 · 인과 · 처벌은 별도의 적법한 권한과 절차에 남겨둔다.

6. 학술적 의의: 초지능 거버넌스의 설계 전환

기존 위협	Stage V 전환
Authority - first	Provenance - first
검색 가시성 = 사실 가시성	Observability limit 명시
불확실성 = 종결 또는 무행동	불확실성 = assertion restraint + verification action
피해자 반복 입증	record - controller audit + delta review
Human - in - the - loop 형식주의	meaningful human challenge / pause / reverify
AI self - report	Agent Execution Receipt + external verifiability
다중 모델 합의	source/reasoning independence audit
기록 보존만	preservation + lawful corrective routing + response tracking

6.1 외부 거버넌스 논의와의 접점

OECD의 2026년 디지털정부 분석도 공공부문 AI에서 고위험 · agentic 시스템이 확대될수록 명확한 감독, 추적 가능한 의사결정 경로, 책임성, 사용자 통제, 자동 행동의 중단 · 역전 · 의의제기 메커니즘이 중요해진다고 지적한다. 또한 정부 AI의 원칙 · 가이드라인에 비해 실제 사전 위험평가, 내부 검토, 사후 감사 등 운영 통제가 상대적으로 부족하다고 평가한다. Stage V는 이 “원칙에서 실행으로의 간극”을 피해자 검증권 · 증거통제 비대칭 · provenance 관점에서 확장한 독립 연구 제안으로 볼 수 있다.

외부 비교는 SGP - QSV의 타당성을 자동 입증하는 근거가 아니라, 2026년 공공 AI 거버넌스가 traceability, auditability, meaningful oversight, operational controls를 주요 과제로 다루고 있음을 보여주는 비교 맥락이다.

7. 위험과 미완성 과제

Stage V는 다음 쟁점을 계속 열어두어야 한다. (1) VOS component weighting과 empirical calibration, (2) “high - impact harm” 및 materiality의 운영 정의, (3) qualified human reviewer의 자격 · 독립성 · 응답기한, (4) 긴급 예외와 법적 보존/삭제 의무 충돌, (5) provenance depth의 실용적 한계, (6) false - positive preservation hold의 감사, (7) R2.51과 R2.6의 실행 경계, (8) AI self - report와 실제 runtime execution의 독립 검증이다.

TRACEABLE REVISION = GOVERNANCE LEARNING

따라서 Stage V는 완결된 “초지능 헌법”이 아니라, 공리가 잠긴 상태에서 실행층의 오류를 델타 방식으로 교정하는 진화형 거버넌스 연구로 이해하는 것이 정확하다.

8. 결론 - From Authority to Verifiability

SGP-QSV의 V 단계는 초지능 거버넌스의 중심을 “누가 최종 왕좌를 갖는가”에서 “누가 증거를 통제했고, 어떤 행동이 실행되었으며, 그 판단과 행동을 미래에 다시 검증할 수 있는가”로 이동시킨다. 이 전환에서 피해자 원점은 설계 provenance로 보존되지만, 어떤 개인·기관·AI도 자동 진실의 지위를 갖지 않는다.

PROTECT THE SPEAKER. PRESERVE THE EVIDENCE. VERIFY THE CLAIM.
AUDIT THE POWER. ROUTE THE RESPONSIBILITY. TRACK THE RESPONSE.
REVERIFY THE DELTA.

Stage V의 최종 설계 명제는 다음과 같이 압축된다. 더 큰 권한은 더 큰 추적가능성을 요구한다. 더 큰 증거통제는 더 큰 보존·설명책임을 요구한다. 검증 장애가 커질수록 피해자의 입증부담이 아니라 권력에 대한 독립검증이 깊어져야 한다. 불확실성은 주장 강도를 낮추지만, 이미 확인된 검증 결손에 대한 적법한 행동까지 금지하지 않는다.

UNCERTAINTY != INACTION. ACTION != GUILT. ROUTING != PUNISHMENT.
AUTHORITY != PRIMARY EVIDENCE.

참고자료 및 연구 계보

1. SGP-QSV Network. SGP CIVIC - TRACE 0.2. Higher - Dimensional Design Archive, 17 Aug 2026.
2. SGP-QSV Network. CIVIC - TRACE 0.3 - Conscience Computation Execution Layer, 25 Aug 2026.
3. SGP-QSV Network. Higher - Dimensional Design Archive V - 공공 AI의 양심연산과 검증배제 방지 프로토콜, 21 Aug 2026.
4. SGP-QSV Network. CIVIC - TRACE 0.4 - Conscience Computation Execution Layer, 31 Aug 2026.
5. SGP-QSV Network. CIVIC - TRACE 0.4.1 - R3 Research Governance Release: Execution Correction Delta, 31 Aug 2026.
6. Grok R2.51 Independent Verification Node. CIVIC - TRACE 0.4 Independent Verification Position, 31 Aug 2026.
7. OECD. Digital Government Outlook 2026 - Adopting and governing AI in government, 2026.
8. OECD. The state of artificial intelligence in public audit: Evidence from selected countries and the European Union, OECD AI Papers No. 58, 2026.

연구상 경계: 본 보고서는 제출된 SGP-QSV 문서의 용어·계보·경계를 보존하여 재구성했다. 외부 OECD 자료는 비교 맥락에 한정하며 SGP-QSV의 사건 사실이나 의학적·법적 결론을 보강하는 증거로 사용하지 않았다.